
Погружение временных рядов с высокой волатильностью в метрическое пространство

A Preprint

Эйнуллаев Алтай
Кафедра интеллектуальных систем
Московский физико-технический институт
Долгопрудный
einullaev.ae@phystech.edu

Яковлев Константин
Кафедра интеллектуальных систем
Московский физико-технический институт
Долгопрудный
iakovlev.kd@phystech.edu

Abstract

Рассматривается задача прогнозирования финансовых временных рядов. Основными особенностями таких временных рядов являются высокая волатильность и высокая попарная ковариация. Классическим подходом к решению задачи является выполнение прогноза в исходном пространстве. Новый метод заключается в переходе в пространство попарных расстояний между временными рядами, осуществлении прогноза в нем и переходе обратно в исходное пространство. Для его реализации необходимо ввести функцию расстояния между временными рядами (метрику), которая должна удовлетворять определенным свойствам. В данной статье изучаются эти свойства и проводятся сравнения различных метрик на основе численных экспериментов.

Keywords Временные ряды · Метрика · Ковариация

1 Introduction

В текущей статье исследуется задача погружения временных рядов в метрическое пространство. Таким образом, набору временных рядов ставится в соответствие матрица попарных расстояний и появляется возможность перейти от прогнозирования набора временных рядов к прогнозированию матрицы попарных расстояний. При этом выбор метрики осуществляется так, чтобы по полученной матрице расстояний можно было восстановить прогноз для набора временных рядов.

В статистике, обработке сигналов и многих других областях под временным рядом понимаются последовательно измеренные через некоторые (зачастую равные) промежутки времени данные. Прогнозирование временных рядов заключается в построении модели для предсказания будущих событий основываясь на известных событиях прошлого, предсказания будущих данных до того как они будут измерены. Типичный пример — предсказание цены открытия биржи основываясь на предыдущей её деятельности.

Одними из хорошо известных, классических методов прогнозирования временных рядов являются экспоненциальное сглаживание (англ. Exponential Smoothing) [1], LSTM (англ. Long Short-Term Memory) [2], ARIMA (англ. autoregressive integrated moving average) [3]. Главным отличием исследуемого метода от вышеперечисленных является то, что временные ряды прогнозируются при помощи прогнозирования матрицы попарных расстояний.

В качестве простейшей метрики рассматривается ковариация между временными рядами. [4] Таким образом, для набора временных рядов получаем матрицу ковариации. Стоит заметить, что матрица ковариации (матрица попарных расстояний) вычисляется в каждый момент времени. Альтернативные варианты метрики выбираются из класса ядер [5].

Численные эксперименты проводятся на трех видах данных: синтетические, сигналы коры головного мозга, финансовые временные ряды. Эксперимент состоит из выполнения прогноза временного ряда

при помощи прогнозирования матрицы попарных расстояний. В качестве прогностической модели выбирается линейная регрессия с использованием SSA (англ. Singular Spectrum Analysis) [6]. По результатам экспериментов проводится анализ точности прогноза и его устойчивости в зависимости от выбранной метрики и вида данных. Цель эксперимента состоит в оптимальном выборе функции попарных расстояний для выполнения прогноза.

2 Problem statement

Пусть $X = \{\mathbf{x} = [x_1, \dots, x_N] | x_i \in R\}$ — множество временных рядов, заданных своей реализацией. Обозначим через

$$\chi = [x^{(1)}, \dots, x^{(n)}]^T \quad (1)$$

заданный набор из n временных рядов. Через $\chi_t = [x_t^{(1)}, \dots, x_t^{(n)}]^T$ обозначим значение ряда χ в момент времени t . Определим функцию расстояния между временными рядами: $d : X \times X \rightarrow R$, удовлетворяющую условиям Мерсера [7]. Обозначим расстояние между временными рядами $x^{(i)} = [x_1^{(i)}, \dots, x_t^{(i)}]$, $x^{(j)} = [x_1^{(j)}, \dots, x_t^{(j)}]$ следующим образом:

$$d(x^{(i)}, x^{(j)}) = d_t(i, j) \quad (2)$$

Таким образом, в каждый момент времени t ряду X поставлена в соответствие матрица попарных расстояний $\Sigma_t \in S_n^+$ (симметричная, положительно полуопределенная матрица):

$$\chi_t \Rightarrow \Sigma_t = \begin{pmatrix} d_t(x^{(1)}, x^{(1)}) & d_t(x^{(1)}, x^{(2)}) & \dots & d_t(x^{(1)}, x^{(n)}) \\ d_t(x^{(2)}, x^{(1)}) & d_t(x^{(2)}, x^{(2)}) & \dots & d_t(x^{(2)}, x^{(n)}) \\ \vdots & \vdots & \ddots & \vdots \\ d_t(x^{(n)}, x^{(1)}) & d_t(x^{(n)}, x^{(2)}) & \dots & d_t(x^{(n)}, x^{(n)}) \end{pmatrix} \quad (3)$$

Дадим описание двум используемым прогностическим моделям:

2.1 Прогнозирование

2.1.1 Авторегрессия

Пусть имеем реализацию матрицы попарных расстояний из N компонент: $\Sigma = [\Sigma_1, \Sigma_2, \dots, \Sigma_N]$. Пусть Σ_{N+1} - прогнозируемая матрица. Авторегрессионная модель:

$$\hat{\Sigma}_{N+1} = \sum_{i=1}^N a_i \Sigma_i + \epsilon_{N+1} \quad (4)$$

где a_1, \dots, a_N — параметры модели (коэффициенты авторегрессии), $\epsilon_{N+1} \in R^{N \times N}$ — белый шум. Вектор параметров определяется с помощью решения задачи оптимизации:

$$a = \arg \min_a \|\Sigma_{N+1} - \hat{\Sigma}_{N+1}\|_F^2 \quad (5)$$

2.1.2 Многомерная гусеница (MSSA)

Пусть имеем реализацию матрицы попарных расстояний из N компонент: $\Sigma = [\Sigma_1, \Sigma_2, \dots, \Sigma_N]$. Определим L - ширина окна, $K = N - L + 1$. В силу того, что матрица симметричная, то для каждой компоненты матрицы попарных расстояний, где $i \leq j$, построим матрицу траекторий (матрица Генкеля):

$$H_{ij} = \begin{pmatrix} d_1(x^{(i)}, x^{(j)}) & d_2(x^{(i)}, x^{(j)}) & \dots & d_K(x^{(i)}, x^{(j)}) \\ d_2(x^{(i)}, x^{(j)}) & d_3(x^{(i)}, x^{(j)}) & \dots & d_{K+1}(x^{(i)}, x^{(j)}) \\ \vdots & \vdots & \ddots & \vdots \\ d_L(x^{(i)}, x^{(j)}) & d_{L+1}(x^{(i)}, x^{(j)}) & \dots & d_N(x^{(i)}, x^{(j)}) \end{pmatrix}. \quad (6)$$

Строим блочную матрицу траекторий:

$$H = [H_{11} : H_{12} : H_{13} : H_{1s} : H_{22} : \dots : H_{ss}] \quad (7)$$

Сингулярное разложение симметричной, положительно полуопределенной матрицы $HH^T = U\Lambda U^T$, где Λ - диагональная матрица $L \times L$ собственных значений $\lambda_1 \geq \dots \geq \lambda_L$, $U = [u_1, \dots, u_L]$ - ортогональная матрица собственных векторов матрицы HH^T . Пусть $d = \max\{i | \lambda_i > 0, i \in \{1, \dots, L\}\}$. Тогда исходную матрицу траекторий можно представить в виде:

$$H = \sum_{i=1}^d \sqrt{\lambda_i} u_i v_i^T = H^{(1)} + \dots + H^{(d)} = \sum_{i=1}^r H^{(i)} + \sum_{i=r+1}^d H^{(i)}, \quad (8)$$

где $v_i = H^T u_i / \sqrt{\lambda_i}$, $H_r = \sum_{i=1}^r H^{(i)}$ - сигнальные компоненты, а $H - H_r$ - шумовые. Полученную матрицу можно представить в виде:

$$H_r = [\tilde{H}_{11} : \tilde{H}_{12} : \dots : \tilde{H}_{ss}] \quad (9)$$

где каждая из матриц $\tilde{H}_{ij} \in R^{N-L+1 \times L}$. Восстановим исходные расстояния с помощью антидиагонального усреднения элементов соответствующих матриц:

$$\tilde{d}_t(i, j) = \frac{1}{2t-1} \sum_{k, l: k+l-1=t} \tilde{h}_{kl}^{(ij)}, t \in \{1, \dots, N\} \quad (10)$$

где $\tilde{h}_{kl}^{(ij)}$ - элемент на пересечении k -ой строки и l -го столбца матрицы H_{ij} . Обозначим через u_j^∇ $L-1$ первые компоненты собственного вектора u_j , а π_j - последнюю компоненту вектора u_j , ($j = 1, \dots, r$).

Определим $v^2 = \sum_{j=1}^r \pi_j^2$ и:

$$\mathcal{R} = \frac{1}{1-v^2} \sum_{j=1}^r \pi_j u_j^\nabla. \quad (11)$$

При $v^2 < 1$ возможен прогноз:

$$[d_{N+1}(1, 1), d_{N+1}(1, 2), \dots, d_{N+1}(s, s)] = \mathcal{R}^T Z \quad (12)$$

где $Z = [Z^{(11)}, \dots, Z^{(ss)}]^T$, $Z^{(ij)} = [\tilde{d}_{N-L+2}(i, j), \dots, \tilde{d}_N(i, j)]$.

2.2 Выбор функции попарных расстояний

Пусть $\mathcal{F} = \{d^{(1)}, \dots, d^{(s)}\}$ - множество функций попарных расстояний, из которого нужно выбрать оптимальный вариант. Пусть $\hat{\Sigma}(d)$ - спрогнозированная, а $\Sigma(d)$ - точная матрица попарных расстояний при использовании $d \in \mathcal{F}$. Тогда оптимальный по точности выбор функции попарных расстояний:

$$d_{\text{acc}} = \arg \min_{d \in \mathcal{F}} \sigma^2(d) = \arg \min_{d \in \mathcal{F}} \|\hat{\Sigma}(d) - \Sigma(d)\|_F^2. \quad (13)$$

Пусть $\tilde{x}^{(i)} = x^{(i)} + \varepsilon_i$, $i = 1, \dots, n$ - зашумленный исходный набор временных рядов, где $\varepsilon_i \in R^N$. Пусть $\tilde{\sigma}^2(d)$ - точность прогноза матрицы попарных расстояний зашумленного набора временных рядов при использовании $d \in \mathcal{F}$. Тогда наиболее устойчивый выбор функции попарных расстояний:

$$d_{\text{stable}} = \arg \min_{d \in \mathcal{F}} |\tilde{\sigma}^2(d) - \sigma^2(d)| \quad (14)$$

Список литературы

- [1] Everette S. Gardner Jr. Exponential smoothing: The state of the art. *Journal of Forecasting*, 1985.
- [2] J. Schmidhuber S. Hochreiter. Long short-term memory. *Neural Computation*, 1997.
- [3] Jenkins Box. *Time Series Analysis: Forecasting and Control*. San Francisco: Holden-Day, 1970.
- [4] Steven Diamond Stephen Boyd, Enzo Busseti and Ronald N. Kahn. Multi-period trading via convex optimization. *Foundations and Trends in Optimization*, 2017.
- [5] John Shawe-Taylor and Nello Cristianini. *Kernel methods for pattern analysis*. Cambridge university press, 2004.
- [6] Robert Vautard, Pascal Yiou, and Michael Ghil. Singular-spectrum analysis: A toolkit for short, noisy chaotic signals. *Physica D: Nonlinear Phenomena*, 58(1-4):95–126, 1992.
- [7] Benyamin Ghojogh, Ali Ghodsi, Fakhri Karray, and Mark Crowley. Reproducing kernel hilbert space, mercer’s theorem, eigenfunctions, nystr\”om method, and use of kernels in machine learning: Tutorial and survey. *arXiv preprint arXiv:2106.08443*, 2021.