

---

# Погружение временных рядов с высокой волатильностью в метрическое пространство

---

A Preprint

Эйнуллаев Алтай  
Кафедра интеллектуальных систем  
Московский физико-технический институт  
Долгопрудный  
einullaev.ae@phystech.edu

Яковлев Константин  
Кафедра интеллектуальных систем  
Московский физико-технический институт  
Долгопрудный  
iakovlev.kd@phystech.edu

## Abstract

Рассматривается задача прогнозирования финансовых временных рядов. Основными особенностями таких временных рядов являются высокая волатильность и высокая попарная ковариация. Классическим подходом к решению задачи является выполнение прогноза в исходном пространстве. Новый метод заключается в переходе в пространство попарных расстояний между временными рядами, осуществлении прогноза в нем и переходе обратно в исходное пространство. Для его реализации необходимо ввести функцию расстояния между временными рядами (метрику), которая должна удовлетво- 1  
рять определенным свойствам. В данной статье изучаются эти свойства и проводятся сравнения различных метрик на основе численных экспериментов.

Keywords Временные ряды · Метрика · Ковариация

## 1 Introduction

В текущей статье исследуется задача погружения временных рядов в метрическое пространство. ~~Таким образом~~, набору временных рядов ставится в соответствие матрица попарных расстояний и появляется возможность перейти от прогнозирования набора временных рядов к прогнозированию матрицы попарных расстояний. При этом выбор метрики осуществляется так, чтобы по полученной матрице расстояний можно было восстановить прогноз для набора временных рядов. 2

В статистике, обработке сигналов и многих других областях под временным рядом понимаются последо- вательно измеренные через некоторые (зачастую равные) промежутки времени данные. Прогнозирование временных рядов заключается в построении модели для предсказания будущих событий основываясь 3  
на известных событиях прошлого, предсказания будущих данных до того как они будут измерены.

4 Типичный пример — предсказание цены открытия биржи основываясь на предыдущей её деятельности.

Одними из хорошо известных, классических методов прогнозирования временных рядов являются экспоненциальное сглаживание (англ. Exponential Smoothing) [1], LSTM (англ. Long Short-Term Memory) [2], ARIMA (англ. autoregressive integrated moving average) [3]. Главным отличием исследуемого метода от вышеперечисленных является то, что временные ряды прогнозируются при помощи прогнозирования матрицы попарных расстояний.

В качестве простейшей метрики рассматривается ковариация между временными рядами. [4] Таким образом, для набора временных рядов получаем матрицу ковариации. Стоит заметить, что матрица ковариации (матрица попарных расстояний) вычисляется в каждый момент времени. Альтернативные варианты метрики выбираются из класса ядер [5].

Численные эксперименты проводятся на трех видах данных: синтетические, сигналы коры головного мозга, финансовые временные ряды. Эксперимент состоит из выполнения прогноза временного ряда

при помощи прогнозирования матрицы попарных расстояний. В качестве прогностической модели выбирается линейная регрессия с использованием SSA (англ. Singular Spectrum Analysis) [6]. По результатам экспериментов проводится анализ точности прогноза и его устойчивости в зависимости от выбранной метрики и вида данных. Цель эксперимента состоит в оптимальном выборе функции попарных расстояний для выполнения прогноза.

## 2 Problem statement

Пусть  $X = \{\mathbf{x} = [x_1, \dots, x_N] | x_i \in R\}$  — множество временных рядов, заданных своей реализацией. Обозначим через

$$\chi = [x^{(1)}, \dots, x^{(n)}]^T \quad 5 \quad (1)$$

заданный набор из  $n$  временных рядов. Через  $\chi_t = [x_t^{(1)}, \dots, x_t^{(n)}]^T$  обозначим значение ряда  $\chi$  в момент времени  $t$ . Определим функцию расстояния между временными рядами:  $d : X \times X \rightarrow R$ , удовлетворяющую условиям Мерсера [7]. Обозначим расстояние между временными рядами  $x^{(i)} = [x_1^{(i)}, \dots, x_t^{(i)}], x^{(j)} = [x_1^{(j)}, \dots, x_t^{(j)}]$  следующим образом:

$$d(x^{(i)}, x^{(j)}) = d_t(i, j) \quad 8 \quad (2)$$

Таким образом, в каждый момент времени  $t$  ряду  $X$  поставлена в соответствие матрица попарных расстояний  $\Sigma_t \in S_n^+$  (симметричная, положительно полуопределенная матрица):

$$\chi_t \Rightarrow \Sigma_t = \begin{pmatrix} d_t(x^{(1)}, x^{(1)}) & d_t(x^{(1)}, x^{(2)}) & \dots & d_t(x^{(1)}, x^{(n)}) \\ d_t(x^{(2)}, x^{(1)}) & d_t(x^{(2)}, x^{(2)}) & \dots & d_t(x^{(2)}, x^{(n)}) \\ \vdots & \vdots & \ddots & \vdots \\ d_t(x^{(n)}, x^{(1)}) & d_t(x^{(n)}, x^{(2)}) & \dots & d_t(x^{(n)}, x^{(n)}) \end{pmatrix} \quad (3)$$

Дадим описание двум используемым прогностическим моделям:

### 2.1 Прогнозирование 10

#### 2.1.1 Авторегрессия

Пусть имеем реализацию матрицы попарных расстояний из  $N$  компонент:  $\Sigma = [\Sigma_1, \Sigma_2, \dots, \Sigma_N]$ . Пусть  $\Sigma_{N+1}$  - прогнозируемая матрица. Авторегрессионная модель:

$$\hat{\Sigma}_{N+1} = \sum_{i=1}^N a_i \Sigma_i + \epsilon_{N+1} \quad (4)$$

где  $a_1, \dots, a_N$  — параметры модели (коэффициенты авторегрессии),  $\epsilon_{N+1} \in R^{N \times N}$  — белый шум. Вектор параметров определяется с помощью решения задачи оптимизации:

$$a = \arg \min_a \|\Sigma_{N+1} - \hat{\Sigma}_{N+1}\|_F^2 \quad 11 \quad (5)$$

#### 2.1.2 Многомерная гусеница (MSSA)

Пусть имеем реализацию матрицы попарных расстояний из  $N$  компонент:  $\Sigma = [\Sigma_1, \Sigma_2, \dots, \Sigma_N]$ . Определим  $L$  - ширина окна,  $K = N - L + 1$ . В силу того, что матрица симметричная, то для каждой компоненты матрицы попарных расстояний, где  $i \leq j$ , построим матрицу траекторий (матрица Генкеля):

$$H_{ij} = \begin{pmatrix} d_1(x^{(i)}, x^{(j)}) & d_2(x^{(i)}, x^{(j)}) & \dots & d_K(x^{(i)}, x^{(j)}) \\ d_2(x^{(i)}, x^{(j)}) & d_3(x^{(i)}, x^{(j)}) & \dots & d_{K+1}(x^{(i)}, x^{(j)}) \\ \vdots & \vdots & \ddots & \vdots \\ d_L(x^{(i)}, x^{(j)}) & d_{L+1}(x^{(i)}, x^{(j)}) & \dots & d_N(x^{(i)}, x^{(j)}) \end{pmatrix}. \quad (6)$$

Строим блочную матрицу траекторий:

$$H = [H_{11} : H_{12} : H_{13} : H_{1s} : H_{22} : \dots : H_{ss}] \quad (7)$$

Сингулярное разложение симметричной, положительно полуопределенной матрицы  $HH^T = U\Lambda U^T$ , где  $\Lambda$  - диагональная матрица  $L \times L$  собственных значений  $\lambda_1 \geq \dots \geq \lambda_L$ ,  $U = [u_1, \dots, u_L]$  - ортогональная матрица собственных векторов матрицы  $HH^T$ . Пусть  $d = \max\{i | \lambda_i > 0, i \in \{1, \dots, L\}\}$ . Тогда исходную матрицу траекторий можно представить в виде:

$$H = \sum_{i=1}^d \sqrt{\lambda_i} u_i v_i^T = H^{(1)} + \dots + H^{(d)} = \sum_{i=1}^r H^{(i)} + \sum_{i=r+1}^d H^{(i)}, \quad (8)$$

где  $v_i = H^T u_i / \sqrt{\lambda_i}$ ,  $H_r = \sum_{i=1}^r H^{(i)}$  - сигнальные компоненты, а  $H - H_r$  - шумовые. Полученную матрицу можно представить в виде:

$$H_r = [\tilde{H}_{11} : \tilde{H}_{12} : \dots : \tilde{H}_{ss}] \quad (9)$$

где каждая из матриц  $\tilde{H}_{ij} \in R^{N-L+1 \times L}$ . Восстановим исходные расстояния с помощью антидиагонального усреднения элементов соответствующих матриц:

$$\tilde{d}_t(i, j) = \frac{1}{2t-1} \sum_{k, l: k+l-1=t} \tilde{h}_{kl}^{(ij)}, t \in \{1, \dots, N\} \quad (10)$$

где  $\tilde{h}_{kl}^{(ij)}$  - элемент на пересечении  $k$ -ой строки и  $l$ -го столбца матрицы  $H_{ij}$ . Обозначим через  $u_j^\nabla$   $L-1$  первые компоненты собственного вектора  $u_j$ , а  $\pi_j$  - последнюю компоненту вектора  $u_j$ , ( $j = 1, \dots, r$ ).

Определим  $v^2 = \sum_{j=1}^r \pi_j^2$  и:

$$\mathcal{R} = \frac{1}{1-v^2} \sum_{j=1}^r \pi_j u_j^\nabla. \quad (11)$$

При  $v^2 < 1$  возможен прогноз:

$$[d_{N+1}(1, 1), d_{N+1}(1, 2), \dots, d_{N+1}(s, s)] = \mathcal{R}^T Z \quad (12)$$

где  $Z = [Z^{(11)}, \dots, Z^{(ss)}]^T$ ,  $Z^{(ij)} = [\tilde{d}_{N-L+2}(i, j), \dots, \tilde{d}_N(i, j)]$ .

## 2.2 Выбор функции попарных расстояний

Пусть  $\mathcal{F} = \{d^{(1)}, \dots, d^{(s)}\}$  - множество функций попарных расстояний, из которого нужно выбрать оптимальный вариант. Пусть  $\hat{\Sigma}(d)$  - спрогнозированная, а  $\Sigma(d)$  - точная матрица попарных расстояний при использовании  $d \in \mathcal{F}$ . Тогда оптимальный по точности выбор функции попарных расстояний:

$$d_{\text{acc}} = \arg \min_{d \in \mathcal{F}} \sigma^2(d) = \arg \min_{d \in \mathcal{F}} \|\hat{\Sigma}(d) - \Sigma(d)\|_F^2. \quad (13)$$

Пусть  $\tilde{x}^{(i)} = x^{(i)} + \varepsilon_i$ ,  $i = 1, \dots, n$  - зашумленный исходный набор временных рядов, где  $\varepsilon_i \in R^N$ . Пусть  $\tilde{\sigma}^2(d)$  - точность прогноза матрицы попарных расстояний зашумленного набора временных рядов при использовании  $d \in \mathcal{F}$ . Тогда наиболее устойчивый выбор функции попарных расстояний:

$$d_{\text{stable}} = \arg \min_{d \in \mathcal{F}} |\tilde{\sigma}^2(d) - \sigma^2(d)| \quad (14)$$

### Список литературы

- [1] Everette S. Gardner Jr. Exponential smoothing: The state of the art. *Journal of Forecasting*, 1985.
- [2] J. Schmidhuber S. Hochreiter. Long short-term memory. *Neural Computation*, 1997.
- [3] Jenkins Box. *Time Series Analysis: Forecasting and Control*. San Francisco: Holden-Day, 1970.
- [4] Steven Diamond Stephen Boyd, Enzo Busseti and Ronald N. Kahn. Multi-period trading via convex optimization. *Foundations and Trends in Optimization*, 2017.
- [5] John Shawe-Taylor and Nello Cristianini. *Kernel methods for pattern analysis*. Cambridge university press, 2004.
- [6] Robert Vautard, Pascal Yiou, and Michael Ghil. Singular-spectrum analysis: A toolkit for short, noisy chaotic signals. *Physica D: Nonlinear Phenomena*, 58(1-4):95–126, 1992.
- [7] Benyamin Ghogh, Ali Ghodsi, Fakhri Karray, and Mark Crowley. Reproducing kernel hilbert space, mercer’s theorem, eigenfunctions, nystr\`om method, and use of kernels in machine learning: Tutorial and survey. *arXiv preprint arXiv:2106.08443*, 2021.

1. Определитесь - метрика или расстояние и оставьте один термин
2. Если расстояние, то здесь должна быть не метрика
3. Нужна ссылка на фундаментальную работу об этом
4. Нужна ссылка, подтверждающая пример
5. Набор из  $n$  временных рядов, видимо, матрица? Тогда жирным. Здесь и далее - сверьтесь с нотацией, которая предлагалась на последнем занятии
6. В прошлом предложении  $\{X_i\}$  было набором из временных рядов, здесь  $\{X_i\}$  - это просто временной ряд. Нужно привести в соответствие
7. Условия можно выписать
8. Справа  $t$  есть, слева нет. Возможно где-то потерялось?
9. Здесь точка, не двоеточие
10. Пустой секции быть не должно, либо убирайте 2.1 и оставляйте сами методы отдельными секциями, либо добавьте текст, который поясняет зачем читателю читать подсекции.
11. Формула - это элемент предложения, соответственно после нее здесь нужна точка. буква  $a$  не может стоять как результат оптимизации (аргминимума) и как переменная, по которой оптимизация проводится (внизу под аргминимумом). Еще: неясно по какому множеству  $a$  пробегает